

Trabalho 1

SME0808 - Séries Temporais e Aprendizado Dinâmico

Arthur Barbosa – N^o USP: 8954937

Bruno Ricardo Pereira dos Santos Santos – N^o USP: 10288640

Sidnei Gazola Junior – N^o USP: 9378888


12 de setembro de 2020

```
knitr::opts_chunk$set(message = FALSE, warning = FALSE,  
                        error = FALSE,fig.dim=c(6,4), fig.pos = "H")
```

```
library(tidyverse)  
library(forecast)  
library(lubridate)  
library(tinytex)  
library(fpp2)  
library(e1071)
```

1.a)

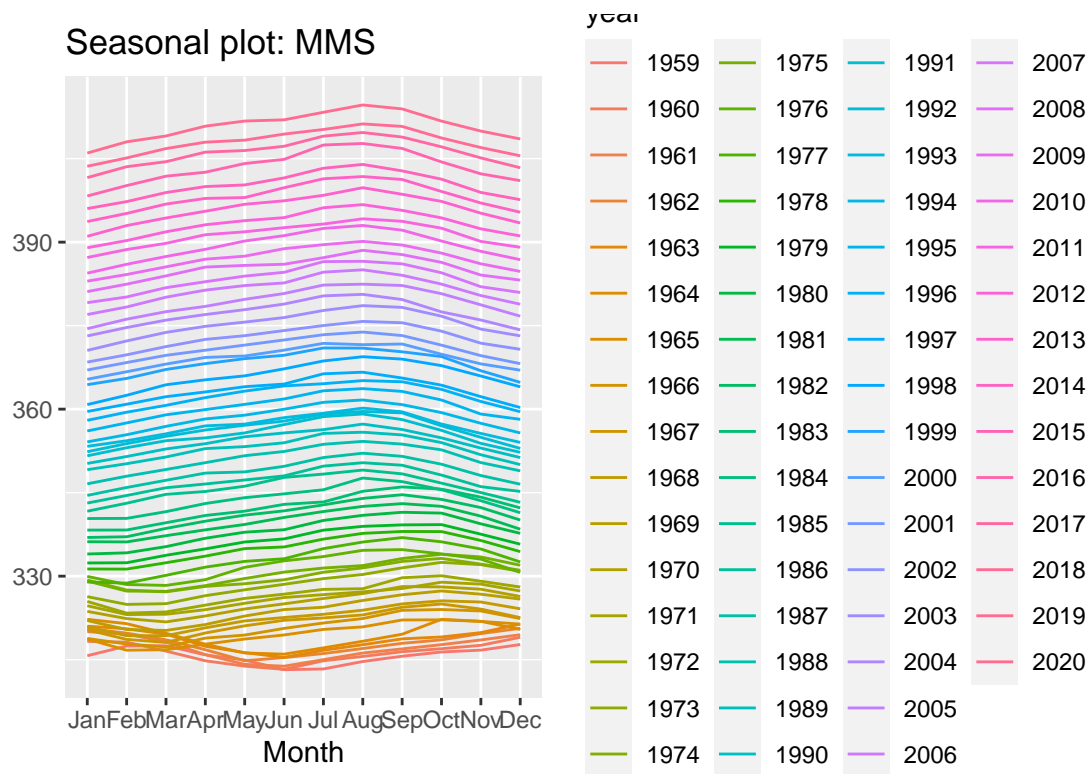
```
co2 <- read_csv("co2_mm_mlo.csv", col_types = cols(year = col_integer(),  
                                                    month = col_integer()))  
  
co2 <- filter(co2,co2$average > 200)  
  
ggplot(data = co2,aes(x=co2$`decimal date`,y=average,color=year)) +  
  geom_line() +  
  theme_bw() +  
  theme(legend.position = "none") +  
  ggtitle("CO2") +  
  labs(x="Data",y= "CO2")
```



Analisando a série é possível identificar uma tendência de alta e variações periódicas anuais dos níveis de co2. Essas variações podem ser melhor vistas por meio do gráfico de sazonalidade.

Análise sazonal

```
MM= read.csv2(file = "media mensal.csv ")  
#criando a série temporal  
MMS= ts(MM[,3], start = c(1959), end = c(2020), frequency = 12)  
View(MMS)  
#Avaliando sazonalidade  
ggseasonplot(MMS)
```



No mês de agosto há uma concentração maior de CO_2 e todos os anos, excetuando-se os primeiros, obedecem a um mesmo padrão sazonal.

1.b)

Obtendo os dados do Dólar, foi possível obter:

```
#Lendo o arquivo
D = read_delim("DOLAR.csv", ";", escape_double = FALSE,
  col_types = cols(Data = col_date(format = "%d/%m/%Y"),
    `31/12/1999` = col_date(format = "%d/%m/%Y")),
  trim_ws = TRUE, skip = 1252)

names(D) = c("data", "taxa")

D <- data.frame (D ,year= year(D$data))

ggplot(data = D,aes(x=data, y=taxa, color = year)) +
  geom_line() +
  theme_bw() +
  theme(legend.position = "none") +
  ggtitle("Dólar x Real") +
  labs(x="Tempo ",y= "Preço")
```



Primeiramente analisando o gráfico da série é perceptível alguns deslocamentos súbitos no preço do dólar, que pode indicar uma aversão a risco e consequente retirada de investimentos de países emergentes como o Brasil. Nos períodos de 2002, 2008, 2015 e 2020, ocorreram respectivamente medo do discurso do Lula durante a campanha, crise do sub-prime, crise fiscal brasileira e a pandemia causada pelo covid-19.


Análise sazonal

```
#criando a série temporal
DS= ts(D[,2], start = c(2000), end = c(2020), frequency = 257)

#Avaliando a série
#ts.plot(DS, lwd = 1, col = "red", xlab = "Tempo", ylab = "Preço")

#Avaliando sazonalidade
ggseasonplot(DS, s= 1000 )
```

Seasonal plot: DS



Analisando o gráfico referente a sazonalidade do Dólar, nenhum padrão estrutural foi observado. O que pode-se notar é um forte aumento do Dólar em anos onde fenômenos de natureza direta ou indiretamente ligada a economia ocorrem, fazendo com que os picos de valores aconteçam nos meses próximos ao fim. A exemplo, podemos notar os anos de 2002, com a eleição presidencial e o ano de 2020, com a pandemia global.

Relação Dólar e Ibovespa

É possível ver relação entre o Dólar e os dados do Ibovespa da próxima questão.

#Entendemos dados tratados como dados que apresentam a mesma frequência de coleta dos dados no mesmo in

#Leitura dos dados: criação do dataframe

```
D = read.csv2(file = "DOLAR_tratado.csv")
```

```
I = read.csv2(file = "IBOVESPA_tratado.csv")
```

#Transformação dos dados em séries temporais

```
Ds = ts(D, start = c(2005), end = c(2020), frequency = 258)
```

```
Is = ts(I, start = c(2005), end = c(2020), frequency = 258)
```

#Normalização dos dados com base em seus valores máximos


```
Dsn = (max(Ds)^(-1)) * Ds
```

```
Isn = (max(Is)^(-1)) * Is
```

#Plot dos dados em conjunto para análise gráfica

```
#ts.plot(Isn, col = "red", main = "Índice IBOVESPA")
ts.plot(Dsn,Isn, col = c("green","red"), main = "Relação: Dolar x IBOVESPA")
legend("topleft", legend=c("Dolar", "IBOVESPA"),
      fill=c("green", "red"), bty="n")
```

Relação: Dolar x IBOVESPA



A relação entre preço do Dolar e o Índice IBOVESPA pode ser observada no gráfico. As duas variáveis, aparentemente, apresentam tendências inversas, ou seja, o crescimento do índice IBOVESPA é acompanhado por um decréscimo do preço do Dolar. O contrário também é verdadeiro. Ambas as variáveis cresceram ao longo dos anos, mas respeitaram a tendência inversa de crescimento entre si. Por se tratar de variáveis que representam fenômenos econômicos do país, recomenda-se uma análise em conjunto a outras variáveis que se propõem ao mesmo objetivo, a exemplo, a taxa SELIC.

2.a)

```
ipea = read_csv("ipeadata[07-09-2020].csv",
               col_types = cols(`02/01/2005` = col_date(format = "%d/%m/%Y")),
               skip = 3836)
names(ipea) = c("data", "indice")

ipea <- filter(ipea, ipea$indice < 200000)

ipea <- data.frame (ipea , year= year(ipea$data))

ggplot(data = ipea, aes(x=data, y=indice, color = year)) +
  geom_line() +
  theme_bw() +
  theme(legend.position = "none") +
  ggtitle("IBOVESPA") +
  labs(x="Data ", y= "IBOVESPA")
```




É uma série com tendência de crescimento no longo prazo, com duas quedas abruptas que correspondem à crise do sub-prime em 2008 e à pandemia em 2020, e com uma tendência de queda entre os anos de 2011 e 2016.

2.b)

```
logr=diff(log(ipea$indice),lag = 1)

ipea <- data.frame (ipea ,logr = c(0,logr))

ggplot(data = ipea,aes(x=data, y=logr, color = year)) +
  geom_line() +
  theme_bw() +
  theme(legend.position = "none") +
  ggtitle("Log-retorno IBOVESPA") +
  labs(x="Data ",y= "Log-retorno")
```




Com o gráfico de log-retorno apresenta suas maiores amplitudes nas crises de 2008 e 2020.

Correlograma

```
acf(logr, lag.max = 10, main = "Correlograma log-retorno", xlab = "Defasagem", ylab = "Autocorrelação")
```


Correlograma log-retorno




Analisando o correlograma do log-retorno, percebe-se que os valores são próximos de zero, logo, que os valores não possuem uma autocorrelação significativa.

2.c)

```
hist(logr, freq = FALSE, main = "Histograma log-retorno",  
      xlab = expression(X), ylab = "Densidade")
```

Histograma log-retorno



```
### Coeficiente de assimetria de Fisher-Pearson
```

```
skewness(logr, type = 1)
```

```
## [1] -0.4066013
```

```
### Coeficiente momento de curtose
```

```
kurtosis(logr, type = 1)
```

```
## [1] 8.620142
```

Como o Coeficiente de assimetria de Fisher-Pearson < 0 , a assimetria é negativa ou à esquerda. Já o Coeficiente momento de curtose > 0 , então a distribuição é leptocúrtica, possui a curva da função de distribuição mais afunilada com um pico mais alto do que a distribuição normal. Essa distribuição possui caudas pesadas, então a função de distribuição é mais achatada do que a distribuição normal.


2.d)

```
qlogr= logr^2
```

```
ipea <- data.frame (ipea ,qlogr = c(0,qlogr))
```

```
ggplot(data = ipea,aes(x=data, y=qlogr, color = year)) +  
  geom_line() +  
  theme_bw() +  
  theme(legend.position = "none") +
```

```
ggtitle("Quadrado do log-retorno IBOVESPA") +
labs(x="Data ",y= "Quadrado do log-retorno")
```




Ao contrário da análise feita através do log-retorno, ao estudarmos o o quadrado do log-retorno podemos observar grandes variações.

Correlograma

```
acf(qlogr, lag.max = 10, main = "Correlograma quadrado do log-retorno",
  xlab = "Defasagem", ylab = "Autocorrelação")
```

Correlograma quadrado do log-retorno



O correlograma do quadrado do log-retorno demonstra auto-correlações não antes vista no log-retorno (que apresentou baixos valores de auto-correlação).